

Анализ рынка недвижимости

Студент: Журавлев М.Е.
Группа: ХБМО-01-23

Раздел 1: Постановка задачи и исходные данные

Рассмотрим базу данных цен на квартиры в Москве.

В данной таблице представлена информация об самих квартирах и их расположению. Задача данной работы - провести анализ рынка недвижимости на основе представленной базы данных и установить параметры, которые влияют на стоимость квартир в Москве.

```
#Загружаем необходимые библиотеки
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
```

```
#Осуществляем чтение файла, сохранение в df и вывод на экран
flats = pd.read_csv('./flats_moscow.csv')
flats
```



	Unnamed: 0	price	totsp	livesp	kitsp	dist	metrdist	walk	brick	floor	code
0	1	81	58	40	6.0	12.5	7	1	1	1	3
1	2	75	44	28	6.0	13.5	7	1	0	1	6
2	3	128	70	42	6.0	14.5	3	1	1	1	3
3	4	95	61	37	6.0	13.5	7	1	0	1	1
4	5	330	104	60	11.0	10.5	7	0	1	1	3
...	...	...	...	...	...	...	...	...	...	...	...
2035	2036	110	77	45	10.0	12.0	5	0	0	1	5
2036	2037	95	60	43	6.0	9.0	5	0	0	1	4
2037	2038	95	60	46	5.0	10.5	5	1	0	1	7
2038	2039	129	76	48	10.0	12.5	5	0	0	1	3
2039	2040	103	64	45	7.0	15.5	5	1	0	1	1

2040 rows x 11 columns

flats.info() #Предварительная общая информация о таблице



```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2040 entries, 0 to 2039
Data columns (total 11 columns):
#   Column      Non-Null Count  Dtype
---  -
0   Unnamed: 0  2040 non-null   int64
1   price       2040 non-null   int64
2   totsp       2040 non-null   int64
3   livesp      2040 non-null   int64
4   kitsp       2040 non-null   float64
5   dist        2040 non-null   float64
6   metrdist    2040 non-null   int64
7   walk        2040 non-null   int64
8   brick       2040 non-null   int64
9   floor       2040 non-null   int64
10  code        2040 non-null   int64
dtypes: float64(2), int64(9)
memory usage: 175.4 KB
```

```
#Размер таблицы
flats.shape
```

(2040, 11)

Датасет flats_moscow.csv (Цены на квартиры в Москве) содержит 2040 строк, 11 столбцов, такие типы данных как int64 и float64. В таблице имеется следующая информация:

- Unnamed: 0: нумерация строк, начиная с 1
- price: цена квартиры в \$1000

- totsp: общая площадь квартиры, кв.м.
- livesp: жилая площадь квартиры, кв.м.
- kitsp: площадь кухни, кв.м.
- dist: расстояние от центра в км.
- metrdist: расстояние до метро в минутах
- walk: 1 – пешком от метро, 0 – на транспорте
- brick: 1 – кирпичный, монолит ж/б, 0 – другой
- floor: 1 – этаж кроме первого и последнего, 0 – иначе.
- code: группы наблюдений по подвыборкам и ближайше линии метро:
 1. Север, вокруг Калужско-Рижской линии метрополитена;
 2. Север, вокруг Серпуховско-Тимирязевской линии метрополитена;
 3. Северо-запад, вокруг Замоскворецкой линии метрополитена;
 4. Северо-запад, вокруг Таганско-Краснопресненской линии метрополитена;
 5. Юго-восток, вокруг Люблинской линии метрополитена;
 6. Юго-восток, вокруг Таганско-Краснопресненской линии метрополитена;
 7. Восток, вокруг Калининской линии метрополитена;
 8. Восток, вокруг Арбатско-Покровской линии метрополитена.

В таблице содержится информация о квартирах, выставленных на продажу. Это включает описание самой недвижимости, и её расположение - географическое, относительно центра и метро.

Данные позволяют провести расчёты и определить параметры, которые влияют на стоимость квартир. Однако необходимо проверить данные на наличие проблем и устранить их. как предварительный анализ показал, что в таблице есть большое количество строк с пустыми значениями по некоторым показателям столбцов. В дальнейшем может также понадобится выделить особые подгруппы данных, на основании одного из параметров, и провести их анализ, чтобы уточнить выводы о зависимости рыночной стоимости квартир.

✓ Раздел 2: Выполнение задачи

✓ Предобработка данных

Удаляем столбец нумерации, так как он не несёт важной информации.

```
flats = flats.drop("Unnamed: 0", axis=1)
```

В таблице предварительной информации у нас отсутствуют пропуски, подтвердим это ещё раз.

```
flats.isna().sum()
```



	0
price	0
totsp	0
livesp	0
kitsp	0
dist	0
metrdist	0
walk	0
brick	0
floor	0
code	0

flats.isna().sum()

Проверим наличие дубликатов

```
flats.duplicated().sum()
```



```
np.int64(43)
```

```
#Удалим дубликаты и проверим их отсутствие
flats = flats.drop_duplicates()
flats.duplicated().sum()
```

```
np.int64(0)
```

Проверим, нужно ли осуществить замену типов данных

```
flats.dtypes
```

	0
price	int64
totsp	int64
livesp	int64
kitsp	float64
dist	float64
metrdist	int64
walk	int64
brick	int64
floor	int64
code	int64

Менять тип текущих данных в основном нигде не требуется, хотя значения walk можно попробовать заменить на категориальные "пешком" или "на транспорте", как способ путешествия до или от метро, или на True/False. Для floor, brick и code следует добавить новые столбцы с значениями-расшифровками. Больше перевода значений нигде не требуется.

Расчёты и добавление новых данных

```
# добавление столбца: цена квадратного метра в $
flats['price_m2'] = flats.price*1000/flats.totsp
```

```
# добавление столбцов: соотношение жилой и общей площади, отношение площади кухни к общей
flats['live_ratio'] = round((flats.livesp / flats.totsp), 2)
flats['kit_ratio'] = round((flats.kitsp / flats.totsp), 2)
```

```
# преобразование столбца walk:
flats['walk'] = flats['walk'].map({1: 'пешком', 0: 'на транспорте'})
```

```
# добавление новых столбцов: floor_category, build_type и select (от selection - выборка)
flats['floor_category'] = flats['floor'].map({1: 'другой', 0: 'первый или последний'})
flats['build_type'] = flats['brick'].map({1: 'кирпичный или монолит', 0: 'другой'})
selection = {1: 'Север, Калужско-Рижская', 2: 'Север, Серпуховско-Тимирязевская',
              3: 'Северо-запад, Замоскворецкая', 4: 'Северо-запад, Таганско-Краснопресненская',
              5: 'Юго-восток, Люблинская', 6: 'Юго-восток, Таганско-Краснопресненская',
              7: 'Восток, Калининская', 8: 'Восток, Арбатско-Покровская'}
flats['select'] = flats['code'].map(selection)
```

Столбец select содержит район (4 разных) и линию метро (7 разных), где была осуществлена выборка. Добавим столбцы, содержащие только один из факторов.

```
flats['area'] = flats['select'].apply(lambda x: x.split(",")[0])
flats['line'] = flats['select'].apply(lambda x: x.split(",")[1])
```

```
#Проверка полученной таблицы
flats.head(5)
```

	price	totsp	livesp	kitsp	dist	metr	dist		walk	brick	floor	code	price_m2	live_ratio	kit_ratio	floor_category	build_type	
0	81	58	40	6.0	12.5		7	пешком		1	1	3	1396.551724	0.69	0.10	другой	кирпичный или монолит	(За
1	75	44	28	6.0	13.5		7	пешком		0	1	6	1704.545455	0.64	0.14	другой	другой	Красн
2	128	70	42	6.0	14.5		3	пешком		1	1	3	1828.571429	0.60	0.09	другой	кирпичный или монолит	(За
3	95	61	37	6.0	13.5		7	пешком		0	1	1	1557.377049	0.61	0.10	другой	другой	Сев
4	330	104	60	11.0	10.5		7	на транспорте		1	1	3	3173.076923	0.58	0.11	другой	кирпичный или монолит	(За

```
flats.iloc[:5, 13:] #Последние колонки для видимости
```

	floor_category	build_type	select	area	line
0	другой	кирпичный или монолит	Северо-запад, Замоскворецкая	Северо-запад	Замоскворецкая
1	другой	другой	Юго-восток, Таганско-Краснопресненская	Юго-восток	Таганско-Краснопресненская
2	другой	кирпичный или монолит	Северо-запад, Замоскворецкая	Северо-запад	Замоскворецкая
3	другой	другой	Север, Калужско-Рижская	Север	Калужско-Рижская
4	другой	кирпичный или монолит	Северо-запад, Замоскворецкая	Северо-запад	Замоскворецкая

```
#Размер исправленной таблицы
flats.shape
```

(1997, 18)

Изучение параметров квартир и их визуализация

Рассмотрим распределение цен за квартиры и их площадей


```
# количественные показатели столбцов с площадью и ценой
flats[['price', 'totsp', 'price_m2']].describe()
```

	price	totsp	price_m2
count	1997.000000	1997.000000	1997.000000
mean	127.748623	73.170756	1719.812608
std	51.933834	15.150229	406.205513
min	50.000000	44.000000	604.651163
25%	95.000000	62.000000	1466.666667
50%	115.000000	74.000000	1607.843137
75%	142.000000	80.000000	1860.465116
max	730.000000	192.000000	5447.761194

```
# график цены квартир
flats.plot(y = 'price', kind = 'hist', bins = 100,
          grid=True, figsize = (8,4))
plt.xlim(0, 800)
plt.title("Стоимость квартир", y=1.02)
plt.xlabel("1.00 = $1000", labelpad=10)
plt.show()
```




Стоимость квартир



```
# график площади квартир
flats.plot(y = 'totsp', kind = 'hist', bins = 80,
          grid=True, figsize = (8,4), color = "MediumSeaGreen")
plt.xlim(0, 200)
plt.title("Площадь квартир", y=1.02)
plt.xlabel("кв. м", labelpad=10)
plt.show()
```




Площадь квартир



```
# график цены за квадратный метр
flats.plot(y = 'price_m2', kind = 'hist', bins = 70,
          grid=True, figsize = (8,4), color = "teal")
plt.title("Цена за квадратный метр", y=1.02)
plt.xlim(0, 6000)
plt.xlabel("в долларах", labelpad=20)
plt.show()
```




Цена за квадратный метр



Рассмотрим распределение долей жилой и кухонной площади по размерам квартир


```
fig = plt.figure()
ax1 = fig.add_subplot(121)
flats.plot(kind = 'scatter', y = 'totsp', x = 'kit_ratio',
            style = 'o', grid=True, figsize = (8,3), color="0.7", ax=ax1)
ax2 = fig.add_subplot(122)
flats.plot( kind = 'scatter', y = 'totsp', x = 'live_ratio',
            style = 'o', grid=True, figsize = (8,3), color="0.2", ax=ax2)
plt.show()
```



Распределение квартир по этажам и типам здания

```
plt.subplot(1, 2, 1)
flats['floor_category'].value_counts().plot(kind='bar', grid=True, figsize = (5,5), color="Goldenrod")
plt.title("Квартиры по этажу", y=1.02)
plt.xlabel("")
plt.subplot(1, 2, 2)
flats['build_type'].value_counts().plot(kind='bar', grid=True, figsize = (5,5), color="maroon")
plt.title("Квартиры по типу здания", y=1.02)
plt.xlabel("")

plt.tight_layout()
plt.show()
```




Распределение квартир по выборке

```
flats['select'].value_counts().plot(kind='bar', grid=True, figsize = (7,3), color="OliveDrab", legend=True)
plt.title("Квартиры по выборке", y=1.02)
plt.xlabel("")
plt.show()
```




Квартиры по выборке



Рассмотрим распределение квартир по расстоянию до метро, и связь между категориями с в столбце walk

```
fig = plt.figure()
ax1 = fig.add_subplot(121)
ax1.set_title("Пешком")
flats[flats["walk"]=="пешком"].plot(y = 'metrdist', kind = 'hist', bins = 20,
                                     grid=True, figsize = (10,3), color = "orange", ax=ax1)
ax1.set_xlabel('мин')
plt.xticks(np.arange(0,20,2.5))

ax2 = fig.add_subplot(122)
ax2.set_title("На транспорте")
flats[flats["walk"]=="на транспорте"].plot(y = 'metrdist', kind = 'hist', bins = 20,
                                             grid=True, figsize = (10,3), color = "b", ax=ax2)
ax2.set_xlabel('мин')
plt.show()
```



✓ Промежуточные выводы по изучению параметров квартир

Минимальное и максимальное значение площади квартир составляют 44 и 192 кв. метров соответственно. Медиана и среднее - 74 и 73,17 кв. метров. Стоимость квартир варьируется от 50 тыс. до 730 тыс. \$.

У нас мало данных о самих квартирах (числе комнат и так далее). Доля кухни обычно составляет 10-20% от площади квартиры, однако есть несколько квартир, средней и ниже площадью, с относительно большими кухнями (возможно, включающими также столовую). Для большинства квартир разных размеров распределение доли жилой площади равномерно, что говорит о наличии разного количества комнат. Самые большие квартиры, по-видимому, содержат много помещений (или большие помещения) другого назначения - кроме ванных и/или туалетов также коридоры, лоджии и другое.

Только около трети квартир расположены в кирпичном или монолитном доме. Скорее всего, большинство квартир расположено в панельных домах.

Больше всего квартир расположено на северо-западе, около замоскворецкой линии метро. Выборки значительно отличаются по размерам - самая малочисленная содержит почти в 1,5 раза меньше квартир.


Исходя из гистограммы распределения квартир по расстоянию до метро, категория walk не зависит от неё, она лишь объясняет, какой способ передвижения имеется ввиду при расчёте времени пути

✚ Поиск и исключение выбивающихся значений

Судя по гистограммам стоимости и площади квартир имеется большой размах между средними и максимальными значениями. Построим диаграмму размаха и проверим наличие выбивающихся значений.

```
#Диаграммы размаха были увеличены для лучшего видения границ усов
fig = plt.figure()
ax1 = fig.add_subplot(131)
flats.plot(y = 'price', kind = 'box', grid=True, figsize = (5,7), ax = ax1,
           return_type="dict")
plt.yticks(np.arange(0, 220, 2), minor=True)
ax1.set_ylim(40, 220)
ax2 = fig.add_subplot(132)
flats.plot(y = 'totsp', kind = 'box', grid=True,figsize = (5,8), ax = ax2)
plt.yticks(np.arange(0, 110, 2), minor=True)
ax2.set_ylim(40, 110)
ax3 = fig.add_subplot(133)
flats.plot(y = 'price_m2', kind = 'box', grid=True,figsize = (5,8), ax = ax3)
plt.yticks(np.arange(0, 2500, 20), minor=True)
ax3.set_ylim(500, 2500)


plt.tight_layout()
plt.show()
```



```
#Приближенные границы диаграммы размаха price_m2
fig = plt.figure()
ax4 = fig.add_subplot(121)
flats.plot(y = 'price_m2', kind = 'box', grid=True,figsize = (5,6), ax = ax4)
plt.yticks(np.arange(0, 2500, 2), minor=True)
```



```
ax4.set_ylim(2400, 2500)
ax5 = fig.add_subplot(122)
flats.plot(y = 'price_m2', kind = 'box', grid=True,figsize = (5,6), ax = ax5)
plt.yticks(np.arange(0, 2500, 2), minor=True)
ax5.set_ylim(900, 1000)
plt.tight_layout()
plt.show()
```



```
#с целью дальнейшего исследования создаём новую таблицу,
#где будут исключены выбивающиеся значения
flats_new = flats.query('(price <= 212) \
                        & (totsp <= 107) \
                        & (price_m2 >= 946 & price_m2 <= 2446)')

flats_new.shape
```

(1821, 18)

```
flats_new[['price', 'totsp', 'price_m2']].describe()
```

	price	totsp	price_m2
count	1821.000000	1821.000000	1821.000000
mean	116.816584	70.734761	1645.376729
std	28.126624	11.113226	257.457904
min	68.000000	44.000000	948.051948
25%	95.000000	61.000000	1464.285714
50%	112.000000	72.000000	1590.909091
75%	135.000000	78.000000	1794.871795
max	210.000000	107.000000	2435.897436

Изучение факторов, которые влияют на стоимость квартиры

Зависимость цены за кв. м от площади


```
#Рассмотрим распределение общей площади и цены за кв. м
price_m2_and_totsp = flats_new.pivot_table(index = 'totsp', values = 'price_m2',
                                             aggfunc = ['count', 'mean', 'median'])

price_m2_and_totsp.columns = ['count', 'mean', 'median']
price_m2_and_totsp.head()
```



	count	mean	median
totsp			
44	1	1704.545455	1704.545455
49	4	1556.122449	1540.816327
50	10	1570.000000	1590.000000
51	25	1604.705882	1549.019608
52	9	1495.726496	1519.230769

```
#Визуализация рапределения
price_m2_and_totsp.plot(y = 'mean', style = 'o', grid=True, figsize = (7,4), color="0.4")
plt.show()
```



```
#Разделим общие площади квартир по квартилям, и рассмотрим распределение по ним
#цены за кв. м
```

```
def totsp_cat(space):
    if space <= 61:
        return "маленькая"
    elif space <= 72:
        return "ниже среднего"
    elif space <= 78:
        return "выше среднего"
    else:
        return "большая"


flats_new['totsp_cat'] = flats['totsp'].apply(totsp_cat)
import warnings
warnings.filterwarnings("ignore")
price_m2_and_totsp_cat = flats_new.groupby('totsp_cat')['price_m2'] \
    .agg(['count', 'sum', lambda x: '{:.8}'.format(x.mean())])
price_m2_and_totsp_cat.columns = ['count', 'sum', 'mean']
price_m2_and_totsp_cat
```



	count	sum	mean
totsp_cat			
большая	428	722707.788848	1688.5696
выше среднего	460	765771.740092	1664.7212
маленькая	482	756299.938597	1569.087
ниже среднего	451	751451.556522	1666.1897

Зависимость цены за кв. м от расстояния до центра

```
#Визуализация зависимости на диаграмме рассеяния
#даёт не совсем явные результаты
flats_new.plot(kind = 'scatter', y = 'price_m2', x = 'dist',
               alpha = 0.05, figsize = (8,4), color="purple")
plt.show()
```



#Рассмотрим зависимость средней цены за кв. м от расстояния до центра


```
dist_mean = flats_new.pivot_table(index = 'dist',
                                   values = 'price_m2',
                                   aggfunc = 'mean')
dist_mean.head(5)
```



	price_m2
dist	
3.0	2021.393771
3.5	1815.966786
4.5	1983.047274
5.0	1960.955720
6.0	1657.186988

#Визуализация в виде графика

```
dist_mean.plot(grid=True, figsize = (8,4), color = "purple")
plt.xlabel("Км")
plt.ylabel("Тыс. $")
plt.show()
```



Зависимость цены за кв. м от расстояния до метро

#Учитывая вид диаграммы рассеяния для расстояния до центра, лучше сразу

#перейдём к зависимости средней цены за кв. м от расстояния до метро

```
metr_mean = flats_new.pivot_table(index = 'metrdist',
                                   values = 'price_m2',
                                   columns = 'walk',
                                   aggfunc = 'mean')
```

#У нас скорее всего могут быть пропуски, для разных категорий walk

#могут быть разный набор значений metrdist.


#Заполним их методом интерполяции

```
metr_mean = metr_mean.interpolate()
metr_mean.head(5)
```



	walk	на транспорте	пешком
metrdist			
1		NaN	1840.973447
2		1770.829171	1818.413235
3		1413.164557	1769.200834
4		1726.513865	1792.009527
5		1615.338687	1729.833835

```
metr_mean.plot(grid=True, figsize = (8,4), color = ("orange", "blue"))  
plt.show()
```



Зависимость цены от этажности и типа здания

```
#Рассмотрим зависимость от этажности в каждом типе здания  
price_and_floor = flats_new.groupby(['build_type', 'floor_category'])['price_m2'] \  
    .agg(['count', lambda x: '{:.2f}'.format(x.sum()), lambda x: '{:.2f}' \  
        .format(x.mean())])  
price_and_floor.columns = ["count", "sum", "mean"]  
price_and_floor
```



		count	sum	mean
build_type	floor_category			
другой	другой	1028	1656930.28	1611.80
	первый или последний	259	400856.26	1547.71
кирпичный или монолит	другой	394	704133.22	1787.14
	первый или последний	140	234311.27	1673.65

Зависимость цены от выборки и района Москвы (для линии метро нецелесообразно рассматривать зависимость).

```
price_and_code = flats_new.groupby(['select'])['price_m2'] \  
    .agg(['count', lambda x: '{:.2f}'.format(x.sum()), lambda x: '{:.2f}' \  
        .format(x.mean())])  
price_and_code.columns = ["count", "sum", "mean"]  
price_and_code = price_and_code.sort_values(by='mean', ascending=False)  
price_and_code
```

	count	sum	mean
select			
Северо-запад, Таганско-Краснопресненская	174	313708.90	1802.92
Восток, Арбатско-Покровская	163	291662.90	1789.34
Север, Калужско-Рижская	238	411549.34	1729.20
Северо-запад, Замоскворецкая	273	470528.93	1723.55
Восток, Калининская	209	333545.38	1595.91
Север, Серпуховско-Тимирязевская	206	327572.04	1590.16
Юго-восток, Таганско-Краснопресненская	239	368293.88	1540.98
Юго-восток. Люблинская	319	479369.65	1502.73

```
price_and_code = flats_new.groupby(['area'])['price_m2'] \
    .agg(['count', lambda x: '{:.2f}'.format(x.sum()), lambda x: '{:.2f}' \
        .format(x.mean())])
price_and_code.columns = ["count", "sum", "mean"]
price_and_code = price_and_code.sort_values(by='mean', ascending=False)
price_and_code
```

	count	sum	mean
area			
Северо-запад	447	784237.82	1754.45
Восток	372	625208.29	1680.67
Север	444	739121.38	1664.69
Юго-восток	558	847663.53	1519.11

Промежуточные выводы для выделения групп квартир для анализа

Зависимость цен за квартиры от расстояния до центра изменяется скачкообразно. Разделить квартиры на условные группы (центр и окраина) не предоставляется возможным.

Аналогичная проблема при рассмотрении зависимость цен от расстояния до метро на транспорте. Однако при учёте пути пешком после 6 мин цены резко падают до примерно постоянного значения. По этой границе можно выделить группу квартир - "Рядом с метро" - и проанализировать зависимость цен в ней.

Из-за наличия только двух категорий рассматривать квартиры только в одной выборке типа строение не является целесообразным.

На северо-западе средняя цена квартир достаточно превышает таковую в других районах. Поэтому эти квартиру также следует рассмотреть отдельно.

Анализ квартир в рядом с метро

```
metro_flats = flats_new.query('(metrdist <= 6) & (walk == "пешком")')
metro_flats.head()
```

	price	totsp	livesp	kitsp	dist	metrdist	walk	brick	floor	code	price_m2	live_ratio	kit_ratio	floor_category	build_type	
2	128	70	42	6.0	14.5	3	пешком	1	1	3	1828.571429	0.60	0.09	другой	кирпичный или монолит	Се Замс
7	88	55	36	6.0	9.0	5	пешком	1	0	4	1600.000000	0.65	0.11	первый или последний	кирпичный или монолит	Се Краснопр
12	142	70	47	8.0	7.5	5	пешком	0	1	3	2028.571429	0.67	0.11	другой	другой	Се Замс
17	175	79	50	9.0	4.5	1	пешком	1	0	8	2215.189873	0.63	0.11	первый или последний	кирпичный или монолит	Восто
21	125	62	40	8.0	12.5	5	пешком	0	1	2	2016.129032	0.65	0.13	другой	другой	С. Тим

metro_flats.iloc[:5, 13:] #Последние колонки для видимости


→

	floor_category	build_type	select	area	line	totsp_cat
2	другой	кирпичный или монолит	Северо-запад, Замоскворецкая	Северо-запад	Замоскворецкая	ниже среднего
7	первый или последний	кирпичный или монолит	Северо-запад, Таганско-Краснопресненская	Северо-запад	Таганско-Краснопресненская	маленькая
12	другой	другой	Северо-запад, Замоскворецкая	Северо-запад	Замоскворецкая	ниже среднего
17	первый или последний	кирпичный или монолит	Восток, Арбатско-Покровская	Восток	Арбатско-Покровская	большая
21	длинной	длинной	Север, Серпуховско-Тимирязевская	Север	Серпуховско-Тимирязевская	ниже среднего

```
metro_flats[['price', 'totsp', 'price_m2']].describe()
```

	price	totsp	price_m2
count	438.000000	438.000000	438.000000
mean	125.381279	71.013699	1757.210165
std	30.233467	11.328658	270.140949
min	73.000000	49.000000	1135.135135
25%	100.000000	62.000000	1536.654135
50%	123.000000	70.500000	1720.870791
75%	145.000000	78.000000	1932.375172
max	210.000000	105.000000	2414.285714

```
#Рассмотрим распределение общей цены и цены за кв. м
price_m2_and_totsp_m = metro_flats.pivot_table(index = 'totsp',
values = 'price_m2', aggfunc = ['count', 'mean', 'median'])
price_m2_and_totsp_m.columns = ['count', 'mean', 'median']
price_m2_and_totsp_m.plot(y = 'mean', style = 'o', grid=True, figsize = (7,4), color="0.4")
plt.show()
```



```
#Распределение по площади
price_m2_and_totsp_cat_m = metro_flats.groupby('totsp_cat')['price_m2'] \
    .agg(['count', 'sum', lambda x: '{:.8}'.format(x.mean())])
price_m2_and_totsp_cat_m.columns = ['count', 'sum', 'mean']
price_m2_and_totsp_cat_m
```

	count	sum	mean
totsp_cat			
большая	108	198147.969844	1834.7034
выше среднего	95	168372.058878	1772.3375
маленькая	108	178207.667693	1650.071
ниже среднего	127	224930.355684	1771.1052

```
#Рассмотрим как влияет на цену выборка по району.
price_and_code_m = metro_flats.groupby(['select'])['price_m2'] \
    .agg(['count', lambda x: '{:.2f}'.format(x.sum()), lambda x: '{:.2f}' \
```

```
.format(x.mean()))]
price_and_code_m.columns = ["count", "sum", "mean"]
price_and_code_m = price_and_code_m.sort_values(by='mean', ascending=False)
price_and_code_m
```

	count	sum	mean
select			
Северо-запад, Замоскворецкая	41	79675.54	1943.31
Восток, Арбатско-Покровская	47	90231.59	1919.82
Северо-запад, Таганско-Краснопресненская	60	110057.30	1834.29
Север, Калужско-Рижская	51	91064.84	1785.59
Восток, Калининская	39	67854.81	1739.87
Север, Серпуховско-Тимирязевская	69	117355.05	1700.80
Юго-восток, Таганско-Краснопресненская	54	88600.80	1640.76
Юго-восток. Люблинская	77	124818.12	1621.01

Анализ квартир в на северо-западе

```
nw_flats = flats_new[flats_new["area"] == "Северо-запад"]
nw_flats.head()
```

	price	totsp	livesp	kitsp	dist	metrdist	walk	brick	floor	code	price_m2	live_ratio	kit_ratio	floor_category	build_type
0	81	58	40	6.0	12.5	7	пешком	1	1	3	1396.551724	0.69	0.10	другой	кирпичный или монолит
2	128	70	42	6.0	14.5	3	пешком	1	1	3	1828.571429	0.60	0.09	другой	кирпичный или монолит
7	88	55	36	6.0	9.0	5	пешком	1	0	4	1600.000000	0.65	0.11	первый или последний	кирпичный или монолит
10	132	96	56	12.0	10.5	7	на транспорте	0	1	3	1375.000000	0.58	0.12	другой	другой
12	142	70	47	8.0	7.5	5	пешком	0	1	3	2028.571429	0.67	0.11	другой	другой


```
nw_flats.iloc[:5, 13:] #Последние колонки для видимости
```

	floor_category	build_type	select	area	line	totsp_cat
0	другой	кирпичный или монолит	Северо-запад, Замоскворецкая	Северо-запад	Замоскворецкая	маленькая
2	другой	кирпичный или монолит	Северо-запад, Замоскворецкая	Северо-запад	Замоскворецкая	ниже среднего
7	первый или последний	кирпичный или монолит	Северо-запад, Таганско-Краснопресненская	Северо-запад	Таганско-Краснопресненская	маленькая
10	другой	другой	Северо-запад, Замоскворецкая	Северо-запад	Замоскворецкая	большая
12	другой	другой	Северо-запад, Замоскворецкая	Северо-запад	Замоскворецкая	ниже среднего

```
nw_flats[['price', 'totsp', 'price_m2']].describe()
```

	price	totsp	price_m2
count	447.000000	447.000000	447.000000
mean	125.062640	70.870246	1754.447036
std	32.137047	12.147124	277.838023
min	70.000000	49.000000	948.051948
25%	98.000000	60.000000	1536.674347
50%	121.000000	71.000000	1724.137931
75%	150.000000	79.000000	1966.758242
max	209.000000	107.000000	2394.366197


```
#Рассмотрим распределение общей цены и цены за кв. м
price_m2_and_totsp_nw = nw_flats.pivot_table(index = 'totsp',
values = 'price_m2', aggfunc = ['count', 'mean', 'median'])
price_m2_and_totsp_nw.columns = ['count', 'mean', 'median']
price_m2_and_totsp_nw.plot(y = 'mean', style = 'o', grid=True, figsize = (7,4), color="0.4")
plt.show()
```




```
#Распределение по площади
price_m2_and_totsp_cat_nw = nw_flats.groupby('totsp_cat')['price_m2'] \
    .agg(['count', 'sum', lambda x: '{:.8}'.format(x.mean())])
price_m2_and_totsp_cat_nw.columns = ['count', 'sum', 'mean']
price_m2_and_totsp_cat_nw
```

	count	sum	mean
totsp_cat			
большая	115	207223.959991	1801.9475
выше среднего	99	178070.602663	1798.693
маленькая	129	210260.867889	1629.9292
ниже среднего	104	188682.394369	1814.2538

```
#Рассмотрим зависимость средней цены за кв. м от расстояния до центра
dist_mean_nw = nw_flats.pivot_table(index = 'dist',
values = 'price_m2', aggfunc = 'mean')
dist_mean_nw.plot(grid=True, figsize = (8,4), color = "purple")
plt.xlabel("Км")
plt.ylabel("Тыс. $")
plt.show()
```



```
#Рассмотрим зависимость средней цены за кв. м от расстояния до метро
metr_mean_nw = nw_flats.pivot_table(index = 'metrdist',
values = 'price_m2',
columns = 'walk',
aggfunc = 'mean')
metr_mean_nw = metr_mean_nw.interpolate()
metr_mean_nw.plot(grid=True, figsize = (8,4), color = ("orange", "blue"))
plt.show()
```

```
#Рассмотрим зависимость от этажности в каждом типе здания
price_and_floor_nw = nw_flats.groupby(['build_type', 'floor_category'])['price_m2'] \
    .agg(['count', lambda x: '{:.2f}'.format(x.sum()), lambda x: '{:.2f}' \
        .format(x.mean())])
price_and_floor_nw.columns = ["count", "sum", "mean"]
price_and_floor_nw
```

		count	sum	mean
build_type	floor_category			
другой	другой	222	379087.88	1707.60
	первый или последний	49	79196.40	1616.25
кирпичный или монолит	другой	131	246611.15	1882.53
	первый или последний	45	79342.40	1763.16

Раздел 3: Выводы

Была выполнена предобработка данных: проверка на пропуски и дубликаты, удалены лишние столбцы и добавлены новые с результатом расчетов ряда показателей.

Далее был проведен исследовательский анализ данных. Было выявлено, что средняя площадь квартир составляет 73,17 кв. м, стоимость - 1719.8 тыс. долларов. Больше данных по строению самих квартир нет, однако зависимость распределения доли жилой площади и кухонной площади от общей площади позволила предположить наличие разного числа комнат в квартирах. Большинство квартир (около 2/3) находится не в кирпичных или в монолитных домах, а в "других" (предположительно, преимущественно панельных).

Между средними показателями и медианными значениями стоимости и общей площади цены большой разницы не имеется, но для цены за кв. м она существенна. Тем не менее, в 4-ом квартиле имеется большой разброс данных, что особенно заметно на гистограммах. При построении диаграммы были обнаружены данные, которые выходили за пределы минимальных и максимальных значений. Они были сочтены за выбросы и удалены. Количество квартир уменьшилось с 1997 до 1821, разница между медианой и средним значением стала гораздо меньше.

Раздел 3: Выводы

Была выполнена предобработка данных: проверка на пропуски и дубликаты, удалены лишние столбцы и добавлены новые с результатом расчетов ряда показателей.

Далее был проведен исследовательский анализ данных. Было выявлено, что средняя площадь квартир составляет 73,17 кв. м, стоимость - 1719,8 тыс. долларов. Больше данных по строению самих квартир нет, однако зависимость распределения доли жилой площади и кухонной площади от общей площади позволила предположить наличие разного числа комнат в квартирах. Большинство квартир (около 2/3) находится не в кирпичных или в монолитных домах, а в "других" (предположительно, преимущественно панельных).

Между средними показателями и медианными значениями стоимости и общей площади цены большой разницы не имеет, но для цены за кв. м она существенна. Тем не менее, в 4-ом квартиле имеется большой разброс данных, что особенно заметно на гистограммах. При построении диаграммы были обнаружены данные, которые выходили за пределы минимальных и максимальных значений. Они были сочтены за выбросы и удалены. Количество квартир уменьшилось с 1997 до 1821, разница между медианой и средним значением стала гораздо меньше.

Цена за квадратный метр жилья зависит от следующих параметров:

- Общая площадь. Маленькие квартиры наиболее дешевые, однако зависимость для средних и больших квартир не совсем явная.
- Расстояние до центра города. Для отдаленных от центра квартир средняя стоимость - наименьшая. Однако при приближении к центру цена растёт неравномерно, скачками, хотя и достигает своего максимального значения в 3 км. Это говорит, что помимо географического центра в Москве имеются и другие "локальные максимумы" по стоимости квартир.
- Расстояние до метро. В случае квартир, от которых можно добраться до метро пешком, цена падает с расстоянием. Для тех, путь от которых требует использование ещё и другого вида транспорта, зависимость менее явная и скачкообразная, хотя в среднем эти квартиры более дешёвые. Это говорит о роли других факторов, как географическое положение, разнообразие доступного транспорта (автобусы, трамваи), и загруженность дорог.
- Этаж квартиры. Первые и последние этажи в среднем более дешёвые. Однако в целом цена на последний этаж может сильно колебаться, и отсутствие информации о соотношении количества первых и последних этажей делает эту зависимость менее практичной для использования.
- Тип здания. Кирпичные и монолитные здания более дорогие, что согласуется с тем фактом, что панельные строения более дешёвые за счёт стоимости строительства.
- Самые дорогие квартиры - на Северо-западе, около Таганско-Краснопресненской метро. Четвертое место по стоимости (очень близко к третьему месту) занимает Замоскворецкая линия, и в целом квартиры на северо-западе более дорогие. Квартиры на юго-востоке наоборот - значительно дешевле остальных.

Анализ цены на недвижимость в Москве позволил выделить группу квартир рядом с метро (т.е. от них можно добраться пешком до метро за 6 или менее минут). Они значительно отличаются по цене от других квартир. Цена за 1 кв. метр выше на 111,8 тыс. \$ (без учёта выбросов). Для квартир рядом с метро немного более явна зависимость стоимости от общей площади - более дороги квартиры среднего размера. Однако при разделении по категориям средняя цена за кв. м значительно больше у крупных квартир. Зависимость цены от региона незначительно отличается от всей выборки. Это говорит о том, что, возможно, географическое положение значительно больше влияет на цену, чем расстояние до метро в целом.

Анализ цены на недвижимость в Москве также позволил выделить группу квартир на северо-западе, в этом районе цена за 1 кв. метр выше на 109,1 тыс. \$ (без учёта выбросов). Для этих квартир зависимость стоимости от общей площади ещё менее явна, чем во всей Москве. Интересно, что на Северо-западе прослеживается более плавная зависимость цены от расстояния до центра с максимумом в 7-9 км. Предположительно, повышенная цена связана с изобилием больших обустроенных парков в этом районе. Зависимость цены от пути до метро менее явна, что подтверждает предыдущее предположение о большей роли географического положения квартир. На северо-западе доля квартир в кирпичных и монолитных зданиях больше, что также способствует увеличению средней стоимости квартир.